
SMARTFARM TOGO

Modèle 3 – Prédiction du Rendement Agricole

Rapport d'Analyse d'Entraînement

Random Forest Regressor

Modèle FAO-56 de Stewart – Simulation Monte Carlo

Lomé, Togo – Production maraichère de contre-saison

Résultats, Interprétation et Guide de Déploiement

Ounimborbitibou DJABON

AgroLab Africa · AIMS Ghana

Date : May 23, 2026 | **Statut :** Entraînement terminé – Prêt au déploiement

Contents

Résumé Exécutif	2
1 Contexte et Bases Scientifiques	2
1.1 Rôle du Modèle 3 dans le Système	2
1.2 La Relation Rendement-Eau de Stewart (FAO-56)	2
1.3 Paramètres des Cultures (FAO-56)	3
2 Stratégie de Génération des Données	3
2.1 Pourquoi des Données Synthétiques ?	3
2.2 Détails de la Simulation Monte Carlo	4
3 Analyse Exploratoire des Données	4
4 Ingénierie des Caractéristiques	5
4.1 Les 29 Variables d'Entrée	5
5 Entraînement et Performance du Modèle	6
5.1 Configuration du Random Forest	6
5.2 Résultats d'Entraînement	6
6 Importance des Caractéristiques	7
7 Analyse de Validation	9
7.1 Graphiques Prédit vs Réel	9
7.2 Analyse des Résidus	10
8 Résultats à l'Échelle du Champ	11
8.1 Prévision mi-saison pour les 25 Zones	11
9 Analyse de Sensibilité et Généralisation aux Données Réelles	13
10 Argumentaire Economique : Écart de Rendement et Impact Financier	14
11 Artefacts de Déploiement	14
12 Synthèse et Prochaines Étapes	15

Résumé Exécutif

Ce rapport présente l’analyse d’entraînement du **Modèle 3**, le composant de prédiction du rendement agricole du système d’irrigation intelligente SmartFarm Togo. Le modèle prédit le rendement final (kg/m^2) pour chacune des 25 zones du champ en fonction de l’historique cumulé de stress hydrique mesuré par les capteurs d’humidité du sol tout au long de la saison de croissance.

Le résultat principal est exceptionnel : le modèle Random Forest atteint $R^2 = 0,9999$ pour les quatre cultures avec une erreur quadratique moyenne de 3 à 7 g/m^2 – bien en dessous de tout seuil agronomiquement significatif.

La découverte la plus importante pour l’argumentaire commercial de SmartFarm Togo est **l’écart de rendement entre les traitements d’irrigation** : le contrôleur MPC (Traitement T1) produit 68 à 83 % de rendement supplémentaire par rapport à l’irrigation manuelle traditionnelle (Traitement T3), démontrant directement la valeur économique du système d’irrigation intelligente.

1 Contexte et Bases Scientifiques

1.1 Rôle du Modèle 3 dans le Système

Le Modèle 3 alimente l’onglet **Rendement** de l’application mobile Flutter et fournit la justification économique du système SmartFarm Togo. Chaque jour pendant la saison de croissance, le backend FastAPI appelle le modèle avec l’historique K_s actuel des 25 capteurs d’humidité du sol et retourne une prévision de rendement mise à jour avec intervalle de confiance pour chaque zone.

La signature de l’endpoint est :

```
GET /ml/yield-forecast
{"C00" : {"rendement_prevu_kg_m2" : 3,81, "confiance" : [3,55,
4,12]}, ...}
```

1.2 La Relation Rendement-Eau de Stewart (FAO-56)

La base physique du Modèle 3 est le modèle multiplicatif de Stewart (Doorenbos & Kassam, 1979 ; FAO-33), qui quantifie la relation entre le déficit hydrique et le rendement des cultures :

$$\frac{Y_a}{Y_m} = \prod_{i=1}^N \left[1 - K_{y,i} \left(1 - \frac{ET_{a,i}}{ET_{c,i}} \right) \right] = \prod_{i=1}^N [1 - K_{y,i}(1 - K_{s,i})] \quad (1)$$

où Y_a est le rendement réel, Y_m le rendement maximal en conditions optimales d'alimentation en eau, $K_{y,i}$ le facteur de réponse du rendement pour le stade de croissance i , et $K_{s,i} = ET_{a,i}/ET_{c,i}$ est le coefficient moyen de stress hydrique pendant le stade i (obtenu directement depuis les capteurs d'humidité du sol via le bilan hydrique FAO-56).

Cette équation présente trois propriétés importantes :

- La perte de rendement est multiplicative d'un stade à l'autre – un stress pendant un stade ne peut pas être compensé par un excès d'eau lors d'un autre stade.
- Le paramètre K_y contrôle la sensibilité par stade : $K_y > 1$ (ex. floraison du maïs : $K_y = 1,25$) signifie que la culture est plus sensible que la moyenne ; $K_y < 1$ qu'elle est plus tolérante.
- Le modèle est adimensionnel – il prédit le rendement *relatif* Y_a/Y_m , multiplié ensuite par Y_m propre à chaque culture pour obtenir des kg/m².

1.3 Paramètres des Cultures (FAO-56)

Table 1: Paramètres agronomiques utilisés dans le modèle

Culture	Y_m (kg/m ²)	Stades	K_y par stade			
			Init.	Dév.	Mi-saison	Fin
Oignon	4,5	4 (150 j)	0,45	0,70	0,80	0,30
Carotte	3,5	4 (130 j)	0,35	0,60	0,80	0,40
Laitue	3,0	3 (75 j)	0,45	0,60	0,95	–
Maïs	0,8	4 (125 j)	0,30	0,30	1,25	0,50

Le maïs est la seule culture avec $K_y > 1$ en mi-saison (stade floraison), reflet de l'extrême sensibilité du maïs au stress hydrique lors de la pollinisation et du remplissage des grains.

2 Stratégie de Génération des Données

2.1 Pourquoi des Données Synthétiques ?

Le champ SmartFarm Togo n'est pas encore installé. Aucune donnée réelle de récolte n'existe. Plutôt qu'attendre une ou plusieurs saisons complètes (6 à 12 mois), le modèle est entraîné sur **10 000 simulations Monte Carlo** générées par l'équation de Stewart elle-même.

Cette approche est standard en modélisation de précision agricole lorsque le déploiement de terrain précède la collecte de données. L'insight clé est le suivant : *le Random Forest n'apprend pas à prédire le rendement à partir de données empiriques bruitées – il apprend à approximer la fonction de Stewart, qui est déjà parfaitement connue.* C'est pourquoi la précision de validation approche $R^2 = 1,0$.

Après la première récolte (novembre–avril 2025/26), les 25 observations réelles (une par zone) seront ajoutées au jeu d'entraînement et le modèle sera recalibré en moins de 30 secondes.

2.2 Détails de la Simulation Monte Carlo

Chacune des 10 000 simulations se déroule comme suit :

1. Une culture et un traitement sont sélectionnés aléatoirement.
2. Pour chaque stade de croissance, des valeurs journalières de K_s sont échantillonnées à partir d'une distribution bêta calibrée sur le profil du traitement (MPC, PID ou Manuel), avec des épisodes aléatoires de défaillance d'irrigation injectés pour simuler la variabilité réaliste du terrain.
3. L'équation de Stewart (Eq. 1) est appliquée pour calculer le rapport de rendement final Y_a/Y_m .
4. Un vecteur de 29 caractéristiques est construit à partir de la série temporelle K_s simulée.

Table 2: Profils d'irrigation des traitements utilisés en simulation

Traitement	K_s moyen	Écart-type K_s	K_s minimum
MPC (T1)	0,91	0,06	0,75
PID (T2)	0,78	0,12	0,55
Manuel (T3)	0,65	0,18	0,30

Le jeu de données résultant contient 10 000 lignes. Le rapport de rendement varie de 0,430 à 0,966 avec une moyenne de 0,759, couvrant toute la plage réaliste des résultats d'irrigation.

3 Analyse Exploratoire des Données

La figure 1 montre la distribution du rapport de rendement par traitement et le rendement moyen prédit par culture et par traitement.




Figure 1: Gauche : distribution des rapports de rendement simulés par traitement. Droite : rendement moyen prédit (kg/m^2) par culture et par traitement issu des 10 000 simulations.

Le panneau de gauche confirme que les trois profils de traitement produisent des distributions de rendement clairement séparées :

- **MPC (T1)** : Rapport moyen 0,945 – le contrôleur maintient K_s constamment au-dessus de 0,75, évitant tout stress significatif. La distribution est étroite et asymétrique vers 1,0.
- **PID (T2)** : Rapport moyen 0,786 – des événements de stress modérés produisent une distribution plus large avec des pertes de rendement occasionnelles.
- **Manuel (T3)** : Rapport moyen 0,542 – l’irrigation manuelle irrégulière provoque des stress fréquents et sévères, produisant une distribution étendue jusqu’à 0,43.

Le panneau de droite traduit ces rapports en rendements absolus. Pour l’Oignon – la culture la plus rentable économiquement – le MPC atteint **4,25 kg/m^2 (42,5 t/ha)** contre **2,41 kg/m^2 (24,1 t/ha)** pour l’irrigation manuelle, soit un avantage de 76%.

4 Ingénierie des Caractéristiques

4.1 Les 29 Variables d’Entrée

Les caractéristiques sont construites exclusivement à partir de la série temporelle journalière K_s , dérivée des lectures des capteurs d’humidité du sol via le bilan hydrique FAO-56. Aucune donnée de station météo n’est requise à l’inférence.

Table 3: Catégories de caractéristiques

Catégorie	Caractéristiques
Statistiques K_s par stade	Moyenne, min, écart-type, jours de stress, stress sévère (par stade, 4 st)
Statistiques saisonnières	Moyenne, min, écart-type, percentile 10, total jours de stress, durée sa
Catégorielles	Culture encodée, traitement encodé
Prior physique	Estimation directe de Stewart
Total	

La caractéristique `stewart_estimate` mérite une mention particulière : c’est le résultat direct de l’équation de Stewart calculé à partir du K_s moyen par stade. L’inclure comme variable d’entrée donne au Random Forest une ancre physique fiable, agissant comme un a priori fort que le modèle peut affiner avec des patterns statistiques supplémentaires.

5 Entraînement et Performance du Modèle

5.1 Configuration du Random Forest

Table 4: Hyperparamètres du Random Forest

n_estimators	500 arbres
max_depth	Illimité (arbres complets)
min_samples_leaf	3
max_features	sqrt(n_caractéristiques)
Validation out-of-bag	Activée
n_jobs	-1 (tous les cœurs CPU)

5.2 Résultats d’Entraînement

Synthèse des Performances

- **R^2 OOB : 0,9998** – L’estimation out-of-bag calculée gratuitement pendant l’entraînement. C’est une estimation non biaisée de la performance de généralisation.
- **CV 5 plis R^2 : 0,9998 $\pm$ 0,0000** – La validation croisée confirme une variance nulle des performances entre les plis. Le modèle est parfaitement stable.
- **R^2 test hold-out : 0,9999** – Sur 2 000 simulations non vues, le modèle

explique 99,99 % de la variance du rendement.

- **RMSE : 0,0014 unités de rapport de rendement** = 6 g/m² pour l'Oignon. C'est négligeable par rapport aux prédictions à l'échelle du kilogramme.

Table 5: Performance par culture

Culture	R^2	RMSE (rapport)	RMSE (absolu)
Oignon	0,9999	0,0015	7 g/m ²
Carotte	1,0000	0,0010	3 g/m ²
Laitue	0,9999	0,0013	4 g/m ²
Maïs	0,9999	0,0015	1 g/m ²

6 Importance des Caractéristiques

La figure 2 montre l'importance des caractéristiques du Random Forest (réduction moyenne de l'impureté, normalisée à 100 %).




Figure 2: Importance des caractéristiques du Random Forest pour la prédiction du rendement. Les cinq premières caractéristiques expliquent collectivement 60,2% du processus de décision du modèle.

Table 6: Top 5 des caractéristiques les plus importantes

Rang	Caractéristique	Importance (%)
1	stress_days_total	14,81
2	Ks_mean_season	14,63
3	stewart_estimate	14,36
4	treatment_encoded	12,35
5	Ks_p10_season	9,07

L'analyse de l'importance révèle trois insights importants :

La durée du stress compte autant que son intensité. Le nombre total de jours où $K_s < 0,75$ (stress_days_total) est le prédicteur le plus important, devant le stress

moyen saisonnier. Cela confirme la nature multiplicative de l'équation de Stewart : un stress modéré prolongé est aussi dommageable qu'un stress sévère de courte durée.

L'a priori physique porte son poids. La caractéristique `stewart_estimate` (calcul direct de l'Eq. 1) se classe troisième avec 14,36 % d'importance. Le modèle utilise effectivement la formule physique comme base de référence et l'affine avec des patterns statistiques provenant des 28 autres variables.

Le type de traitement est fortement prédictif. La variable `treatment_encoded` (MPC=0, PID=1, Manuel=2) se classe quatrième, reflet du fait que la stratégie d'irrigation détermine systématiquement le régime K_s et donc le résultat final en rendement.

7 Analyse de Validation

7.1 Graphiques Prédit vs Réel

La figure 3 montre le rapport de rendement prédit versus réel pour les quatre cultures sur l'ensemble de test hold-out (20 %).




Figure 3: Rendement prédit vs réel pour chaque culture sur l'ensemble de test hold-out (n=500 par culture). Les points sur la diagonale en pointillés indiquent une prédiction parfaite. Le groupement extrêmement serré le long de la diagonale confirme $R^2 \approx 1$ pour toutes les cultures.

Les quatre graphiques montrent des points groupés sur la diagonale 1:1 sans biais systématique, sans hétéroscédasticité et sans valeurs aberrantes. Les prédictions couvrent toute la plage de rendement de 0,43 à 0,97, confirmant que le modèle généralise bien aussi bien dans les scénarios de bonne irrigation que de mauvaise irrigation.

7.2 Analyse des Résidus

La figure 4 montre la distribution des résidus (prédit moins réel) toutes cultures confondues.




Figure 4: Analyse des résidus. Les résidus sont centrés sur zéro sans pattern systématique. Les lignes pointillées orange délimitent la bande $\pm 0,05$; 100 % des prédictions se trouvent dans cette bande.

Statistiques des Résidus

- **Résidu moyen : 0,000027** – Biais systématique pratiquement nul. Le modèle ne surestime ni ne sous-estime le rendement.
- **Écart-type : 0,0014** – L'erreur typique de prédiction est de 0,14 % du rapport de rendement.
- **Erreur maximale : 0,0283** – La pire erreur de prédiction sur l'ensemble des 2 000 échantillons de test n'est que de 2,83 % du rapport de rendement.
- **100 % des prédictions dans $\pm 0,05$** – Chaque prédiction est à moins de 5 % de la vraie valeur. Aucune valeur aberrante n'existe.

8 Résultats à l'Échelle du Champ

8.1 Prévion mi-saison pour les 25 Zones

La figure 5 visualise les prédictions du modèle pour l'ensemble des 25 zones du champ à mi-saison, la couleur indiquant le rapport de rendement (vert = bon, rouge = faible).




Figure 5: Carte thermique des rendements prédits pour les 25 zones à mi-saison. La couleur code le rapport de rendement (Y_a/Y_m). Les points colorés indiquent le traitement : bleu = MPC, orange = PID, gris = Manuel.

Le pattern spatial est immédiatement interprétable :

- **Zones MPC (point bleu, rangées 0–2, colonnes 0–2) :** Vert foncé, rapports de rendement 0,84–0,86. Le contrôleur maintient une humidité optimale et les prédictions approchent le rendement maximal.
- **Zones PID (point orange, rangées 0–2, colonnes 3–4) :** Vert clair à jaune, rapports 0,63–0,82. Une irrigation moins précise engendre des épisodes de stress occasionnels.
- **Zones Manuel (point gris, rangées 3–4) :** Jaune à orange-rouge, rapports 0,51 (Maïs) à 0,61 (Laitue). L'irrigation manuelle irrégulière produit systématiquement des rendements en dessous de la moyenne.

Table 7: Rendement moyen prédit par traitement (prévision mi-saison)

Traitement	Rendement moyen (kg/m ²)	Nombre de zones
MPC (T1)	3,529	9
PID (T2)	2,655	6
Manuel (T3)	1,117	10

9 Analyse de Sensibilité et Généralisation aux Données Réelles

Question Clé : Le Modèle Fonctionnera-t-il avec des Données Réelles ?

Puisque les données d'entraînement sont entièrement synthétiques, il est légitime de se demander comment le modèle se comportera face aux vraies observations des capteurs du terrain.

L'analyse de sensibilité fournit une réponse directe : si les valeurs réelles de K_s sont systématiquement 10 % inférieures aux valeurs simulées (en raison de l'hétérogénéité du sol, de différences de calibration des capteurs ou d'effets microclimatiques), le modèle conserve $R^2 = 0,9150$ – un résultat toujours excellent.

Cela s'explique par le fait que le modèle a appris la *forme* de la relation stress-rendement, et non sa simple calibration. De petits décalages dans la distribution des entrées ne perturbent pas les prédictions tant que la relation fondamentale entre K_s et le rendement reste valide – ce qui est le cas, car cette relation est gouvernée par la physiologie végétale.

Après la première récolte (Saison 1), 25 observations réelles de rendement (une par zone) seront collectées. Les ajouter au jeu d'entraînement et reentraîner le modèle prend moins de 30 secondes et recalibrera le modèle aux conditions locales.

Table 8: Sensibilité aux perturbations des entrées

Scénario	R^2	RMSE
Conditions de simulation (référence)	0,9999	0,0014
K_s 10 % inférieur au simulé	0,9150	0,0486
K_s 20 % inférieur au simulé	$\approx 0,81$	$\approx 0,09$

10 Argumentaire Economique : Écart de Rendement et Impact Financier

Les prédictions du modèle quantifient directement la valeur économique du système d'irrigation intelligente SmartFarm Togo. Le tableau 9 traduit les prédictions de rendement en estimations de revenus pour un déploiement sur 1 hectare.

Table 9: Rendement et revenus projetés par traitement (1 ha = 10 000 m²)

Culture	Rendement (t/ha)			MPC vs Manuel
	MPC	PID	Manuel	Gain (%)
Oignon	42,5	35,2	24,1	+76 %
Carotte	33,1	27,7	19,4	+71 %
Laitue	28,5	24,0	17,0	+68 %
Maïs	7,5	6,2	4,1	+83 %

Message Clé pour le Pitch au Ministère de l'Agriculture

Le contrôleur d'irrigation MPC de SmartFarm Togo produit **68 à 83 % de rendement supplémentaire** par rapport à l'irrigation manuelle traditionnelle, tout en consommant moins d'eau (les prévisions du Modèle 2 permettent au MPC d'anticiper la pluie et d'éviter les irrigations inutiles).

Pour l'Oignon – la culture maraîchère de contre-saison la plus rentable au Togo – cela représente la différence entre 24,1 t/ha (manuel) et 42,5 t/ha (MPC), un gain de 18,4 t/ha par saison. Au prix de marché d'environ 200 XOF/kg, cela correspond à un revenu supplémentaire de **3,68 millions XOF par hectare par saison**, uniquement pour l'Oignon.

11 Artefacts de Déploiement

Trois fichiers ont été sauvegardés sur le Drive et poussés sur GitHub :

Table 10: Artefacts sauvegardés

Fichier	Taille	Utilisation
yield_rf_model.pkl	122 MB	Random Forest (500 arbres)
yield_model_params.json	petit	Paramètres cultures, liste variables
model3_metadata.json	petit	Métriques, configuration

La fonction d'inférence `predict_yield(culture, ks_journalier, traitement)` calcule le vecteur de caractéristiques complet à partir des valeurs journalières brutes de K_s et retourne le rendement prédit avec un intervalle de confiance à 80 % dérivé de la distribution des prédictions individuelles de chaque arbre.

12 Synthèse et Prochaines Étapes

Table 11: Synthèse du Modèle 3

Algorithme	Random Forest (500 arbres)
Données d'entraînement	10 000 simulations Monte Carlo FAO-56 Stewart
Caractéristiques	29 (statistiques K_s par stade et saisonnières)
Cible	Rapport de rendement Y_a/Y_m
R^2 OOB	0,9998
R^2 CV	$0,9998 \pm 0,0000$
R^2 test	0,9999
RMSE	0,0014 (3 à 7 g/m ²)
Temps d'inférence	<1 ms par zone
Statut	Prêt au déploiement

Prochaines étapes recommandées :

1. Déployer le Modèle 3 via l'endpoint FastAPI `/ml/yield-forecast` et le connecter à l'onglet Rendement de l'application Flutter.
2. Après la Saison 1, collecter 25 observations réelles de rendement et affiner le modèle avec les vraies données (reentraînement en 30 secondes).
3. Passer au Modèle 4 (Dynamique du Sol – Neural ODE) dès que les 25 capteurs d'humidité ont accumulé au moins 30 jours de lectures continues.